

动态噪声的竞争深度 Q 网络 *

张鑫, 张席

(深圳大学 计算机与软件学院, 深圳 518061)

摘要: 深度强化学习通常是通过在动作空间注入噪声来进行探索, 但难以根据学习状况进行调整。另一种方法是在参数空间加入噪声, 使得探索更加丰富, 但会大幅减缓训练过程, 使得收敛速度变慢。针对这个问题, 提出了结合竞争网络结构和动态噪声的方法, 即在动作空间与参数空间均加入噪声, 动态地结合了各自优点。在训练前期以动作空间的噪声为主, 减少神经网络的参数学习压力, 从而更快的适应环境。利用测试平台 OpenAI Gym 进行对比实验, 结果表明提出的方法取得了更好的学习性能, 训练稳定性有明显提升。

关键词: 深度 Q 网络; 强化学习; 探索与利用

中图分类号: TPxxx [查询请参考 <http://ztlh.xhma.com>]

Dueling Deep Q Network with Dynamic Noise

Zhang Xin, Zhang Xi

(College of Computer Science and Software Engineering of Shenzhen University, Shenzhen 518061, China)

Abstract: Deep reinforcement learning generally engage in exploratory behavior through noise injection in the action space, but it is difficult to adjust according to the training situation. An alternative is to add noise directly to the parameter space, which can lead to a richer set of behaviors, but also slow down the training process and the convergence speed greatly. To address this problem, a method combining dueling network and dynamic noise is proposed, that is, adding noise both to the action space and parameter space. In the early stage of training, the noise in the action space is mainly used to reduce the parameter learning pressure of the neural network, so as to adapt to the environment more quickly. The OpenAI Gym was used for comparison experiment. The results show that the proposed method achieved better learning performance and significantly improved training stability.

Key words: DQN; Reinforcement Learning; exploration and exploitation

0 引言

强化学习的基本学习方法是通过智能体在一定时间步中, 不断的采取动作与所在环境进行交互, 观测到环境对当前智能体状态、动作的反馈信号后调整下一步动作, 从而提升自身的表现性能。在结合深度学习之前, 传统的强化学习算法如 Q-Learning^[1]利用 Q 表来存储状态动作映射的 Q 值, 但在高维度状态的环境中其状态空间巨大, 保存每个状态的 Q 值会有存储空间浪费、查表效率低下等问题, 故局限于低维度状态的环境。深度强化学习将深度学习的高维度感知处理能力与强化学习的决策能力相结合, 取得了实质性的突破^[2]。

Mnih V 等人^[3]首次提出将深度学习与强化学习算法 Q-Learning 结合的方法, 即 DQN (Deep Q-network) 深度强化学习, 直接将预处理后的原始图片像素作为深度神经网络的输入,

预测该输入对应的 Q 值, 输出要选择的动作, 在部分 Atari 2600 游戏^[4]中取得了超过人类玩家的分数^[5]。双 DQN^[6] (Double DQN) 方法采用不同网络参数来对 Q 值进行估计, 解决 DQN 的过估计问题。竞争网络^[7] (Dueling Network) 改进原本的网络结构, 将原始 DQN 的输出解耦成两个分支, 分别预测作为标量的状态值函数, 与作为矢量的优势函数, 后者中的每个值对应一个动作, 两个函数相加输出每个动作的 Q 值, 提升函数近似效果。为了平衡强化学习中探索和利用之间的关系, 通常是在动作空间加入噪声, 如 ϵ -greedy 策略^[1], 但参数 ϵ 是单调递减的线性函数, 对于动态的学习过程, 并不能完全适应。文献[8]和文献[9]分别提出两种在参数空间加入噪声的方法, 引起网络输出变化, 从而影响选择的动作。本文采用动作空间噪声与参数空间噪声动态结合的竞争深度 Q 网络针对控制问题进行研究, 在 OpenAI Gym 提供的控制问题环境中取得了更高的分数。

作者简介: 张鑫 (1994-), 男, 广东揭阳人, 硕士研究生, 主要研究方向为深度强化学习 (296232375@qq.com); 张席 (19XX-), 男/女 (民族) (通信作者), 籍贯, 职称, 职务, 学位, 主要研究方向为…… (abcdefg@abcd.com [通信作者一定要写邮箱地址, 若没有通信作者, 邮箱则标注第一作者的]); 作者姓名 3 (19XX-), 男/女 (民族), 籍贯, 职称, 职务, 学位, 主要研究方向为……。

1 强化学习

1.1 强化学习算法

强化学习与传统的搜索策略不同, 与环境进行交互的智能体能够通过学习环境中采集的样本, 获得从状态到动作的映射, 从而更快的得到最优的动作。强化学习的应用场景假设遵循马尔科夫性^[10], 只需要当前步的状态信息, 即可预测出一个合理的动作, 执行动作到环境中得到反馈回报奖励, 针对状态 s_t 回报奖励为:

$$R_{t+1} = \sum_{s_{t+1}, r_{t+1}} p(s_{t+1}, r_{t+1} | s_t, a_t) r_{t+1} \quad (1)$$

其中, 智能体在在状态 s_t 下执行的动作 a_t 达到下一个状态 s_{t+1} , 并获得 r_{t+1} 奖励的概率为 $p(s_{t+1}, r_{t+1} | s_t, a_t)$ 。状态动作值函数 $Q(s_t, a_t)$ 表示状态 s 在 t 时间步下执行动作 a 获得的期望回报, 折扣因子 γ 表示未来反馈回报对当前期望回报的影响程度, 根据公式(1)递推, 可得到递归公式^[11]:

$$Q(s_t, a_t) = \sum_{s_{t+1}, r_{t+1}} p(s_{t+1}, r_{t+1} | s_t, a_t) [r_{t+1} + \gamma Q(s_{t+1}, a_{t+1})] \quad (2)$$

给定一个确定性策略 π , 为获得更优策略 $\pi' (\pi' > \pi)$, 不断更新使其接近最优策略 π_* , 记动作 $a = \pi(s)$, 则:

$$Q_*(s, a) = Q_\pi(s, \pi_*(s)) = \max_{\pi} Q_\pi(s, a) \quad (3)$$

结合公式(2)(3)推导, 可得 Q -Learning 算法^[12]公式如下:

$$Q(s_t, a_t) = Q(s_t, a_t) + \alpha [R_{t+1} + \gamma \max_a Q(s_{t+1}, a_{t+1}) - Q(s_t, a_t)] \quad (4)$$

状态动作函数值通过映射表的方式进行存储, 但在高维度问题下, 巨大的映射表占用大量的存储空间, 并且有查表效率低下等问题。

1.2 深度 Q 网络

传统 Q -Learning 算法在大部分现实问题中, 面临“维度灾难”问题。深度 Q 网络以神经网络为非线性函数, 利用函数近似解决获取 Q 值的问题, 即:

$$\hat{Q}(s, a, \theta) \approx Q_\pi(s, a) \quad (5)$$

定义损失函数来更新网络参数 θ , 即:

$$L(\theta) = \mathbb{E}_\pi \left[\left(Q_\pi(s, a) - \hat{Q}(s, a, \theta) \right)^2 \right] \quad (6)$$

Q -Learning 算法属于无模型的 TD (Temporal Difference) 算法^[1], 即不用等到训练回合结束, 每步更新 Q 值, 并通过自举来预测真实样本值。深度 Q 网络结合 Q -Learning 算法来近似 TD 目标。设当前步为 t 步, TD 目标为:

$$R_{t+1} + \gamma \max_a \hat{Q}(s_{t+1}, a_{t+1}, \theta) \quad (7)$$

由上可见, TD 目标与网络近似输出的 Q 值用的是同一套参数 θ , 在训练过程中一起发生改变, 导致影响收敛的问题, 使用目标网络^[5]替换 TD 目标中当前网络的部分可解决该问题, 记为 $\hat{Q}(s, a, \theta^-)$, 同时以一定的更新频率更新目标网络。

根据公式(6)(7), 深度 Q 网络以网络近似输出的 Q 值与 TD 目标之间的误差定义的损失函数为:

$$L(\theta) = \mathbb{E}_\pi \left[\left(R_{t+1} + \gamma \max_a \hat{Q}(s_{t+1}, a_{t+1}, \theta^-) - \hat{Q}(s, a, \theta) \right)^2 \right] \quad (8)$$

1.3 改进的竞争网络

竞争结构将状态动作值函数 $Q^\pi(s, a)$ 解耦成状态值函数与动作优势函数, 定义为:

$$Q^\pi(s, a) = A^\pi(s, a) + V^\pi(s) \quad (9)$$

其中, 状态值函数 $V^\pi(s)$ 表示在状态 s 下由特定策略 π 产生的期望回报值, 动作优势函数 $A^\pi(s, a)$ 表示在状态 s 下由特定策略 π 选择动作 a 带来的优势值。

将竞争结构应用到神经网络中, 即把深度 Q 网络的原始输出分为两个全连接层流, 分别对应状态值函数、动作优势函数, 记为:

$$Q(s, a; \theta, \alpha, \beta) = V(s; \theta, \beta) + A(s, a; \theta, \alpha) \quad (10)$$

其中, θ 表示用于进行特征处理的卷积层的参数, α, β 分别为动作优势层、状态值层的参数, $V(s; \theta, \beta)$ 对应状态值函数, 输出为标量, $A(s, a; \theta, \alpha)$ 对应动作优势函数, 输出为矢量, 矢量大小对应动作空间的大小。

由于网络最后的输出是状态动作值函数 Q 值, 即在公式(10)中, 状态值函数 V 与动作优势函数 A 无法被复原, 表明 V 不能反映出状态值, A 不能反映出优势值。

因此将动作优势函数的输出矢量和设置为 0, 即:

$$A(s, a; \theta, \alpha) = A(s, a; \theta, \alpha) - \max_{a'} (s, a'; \theta, \alpha) \quad (11)$$

为了提高实际应用的稳定性, 更好地反映优势变化以获得最优的行动, 将公式(11)更改为:

$$A(s, a; \theta, \alpha) = A(s, a; \theta, \alpha) - \sum_a A(s, a'; \theta, \alpha) / |A| \quad (12)$$

因此, 竞争网络结构能在无监督的情况下, 自动地分别对状态价值函数 V 与动作优势函数 A 产生近似预估。更具体地说, 竞争结构不需要了解每个状态对应每个动作的价值, 也能决定哪些状态是有价值的。

2 动态噪声模型

2.1 ϵ -greedy 策略

在 Q -Learning 算法中, 智能体获得最优动作的策略是选取最大 Q 值对应的动作, 但在训练初期的阶段, 智能体对环境了解的信息较少, 获得的 Q 值并不能准确的反映最优的动作, 影响训练表现。

因此, 需要在探索过程中加入一定随机性, 即 ϵ -greedy 策略, 在动作空间中引入参数 $\epsilon (\epsilon \in [0, 1])$, 在 ϵ 概率下, 智能体会随机选择动作, 能在面对未知环境时, 收集到更多信息。而随着训练时间进行, 智能体获取到较多的环境信息, 概率 ϵ 单调衰减到一个固定值, 从而减少智能体随机选取动作的可能性。

2.2 参数空间噪声

考虑在神经网络中加入高斯噪声作为参数, 与 ϵ -greedy 策略不同的是, 建立噪声分布, 从分布中取样后注入到其他可训

练的参数中, 在神经网络中引起扰动, 同样利用梯度下降进行参数学习。而 ε -greedy 策略在动作空间加入噪声, 并不会影响网络输出, 且参数 ε 若下降过快, 则未必能保证智能体学习到最优策略。

对有 p 个输入和 q 个输出的线性单元可表示为:

$$y = w \cdot x + b \quad (13)$$

其中, $x \in R^{p \times 1}$ 对应输入向量, $y \in R^{q \times 1}$ 对应输出向量, $w \in R^{p \times q}$ 对应隐藏层的参数, $b \in R^{q \times 1}$ 对应偏置值。

将 w 表示为一个分布, 记为 $w \sim N(\mu^w, \sigma^w)$, 建立噪声分布 $\epsilon^w \sim N(0,1)$, 从噪声分布中采样, 则:

$$w = \mu^w + \sigma^w \odot \epsilon^w \quad (14)$$

其中, $\mu^w \in R^{p \times q}$ 对应均值, $\sigma^w \in R^{p \times q}$ 对应方差, 同理对偏置值做同样改动, 则线性单元可表示为:

$$y = (\mu^w + \sigma^w \odot \epsilon^w) \cdot x + \mu^b + \sigma^b \odot \epsilon^b \quad (15)$$

2.3 动态噪声

3 实验结果与分析

3.1 实验设计

3.2 实验结果分析

4 结束语

参考文献

- [1] Sutton R.S, Barto A.G. Reinforcement learning: An introduction [J]. IEEE Transactions on Neural Networks, 1998, 9(5):1054-1054.
- [2] 刘全, 翟建伟, 章宗长, 等. 深度强化学习综述 [J]. 计算机学报, 2018, 41(1): 1-27. (Liu Quan, Zhai Jianwei, Zhang Zongchang, et al. A survey on deep reinforcement learning [J]. Chinese Journal of Computers, 2018, 41(1): 1-27.)
- [3] Mnih V, Kavukcuoglu K, Silver D, et al. Playing atari with deep reinforcement learning. arXiv preprint arXiv: 1312. 5602, 2013
- [4] Bellemare M G, Naddaf Y, Veness J, et al. The arcade learning environment: An evaluation platform for general agents[J]. Journal of Artificial Intelligence Research, 2012, 47(1): 253-279.
- [5] Mnih V, Kavukcuoglu K, Silver D, et al. Human-level control through deep reinforcement learning [J]. Nature, 2015, 518: 529-533.
- [6] Van H, Guez A, Silver D. Deep reinforcement learning with double q-learning [C]// Thirtieth AAAI conference on artificial intelligence, 2016
- [7] Wang Z, Schaul T, Hessel M, et al. Dueling Network Architectures for Deep Reinforcement Learning [C]// Proc of the 33rd International Conference on Machine Learning, 2016.
- [8] Plappert M, Houthoofd R, Dhariwal P, et al. Parameter space noise for exploration. arXiv preprint arXiv:1706.01905, 2017
- [9] Fortunato M, Azar MG, Piot B, et al. Noisy networks for exploration. arXiv preprint arXiv:1706.10295, 2017
- [10] 邱祎, 董彦彦. 基于马尔可夫过程的线性规划方法探讨 [J]. 统计与决策, 2017, 10: 88-90. (Qiu Yi, Dong Yanyan. Linear programming method based on Markov process [J]. Statistics & Decision, 2017, 10: 88-90.)
- [11] Dolcetta IC, Ishii H. Approximate solutions of the Bellman equation of deterministic control theory[J]. Applied Mathematics and Optimization. 1984, 11(1):161-81.
- [12] Watkins C J C H, Dayan P. Q - learning[J]. Machine Learning, 1992, 8: 279-292.
- [13] Osband I, Russo D, Wen Z, et al. Deep exploration via randomized value functions[J], Journal of Machine Learning Research, 2017.